

Uso de modelo de Machine Learning para detección de genes de resistencia a antibióticos en microbiota intestinal porcina

Juan Jerónimo Gómez Rubiano

Abstract—La detección de genes de resistencia a antibióticos (ARG) en datos metagenómicos se realiza tradicionalmente por homología de secuencia contra bases de datos curadas como CARD, un enfoque que solo identifica lo que ya está catalogado. Este trabajo explora si un modelo de aprendizaje automático puede aprender un patrón composicional de "gen de resistencia" basado en la frecuencia de tetranucleótidos (k-mers de ADN) a partir únicamente de las secuencias de referencia de CARD, y si dicho patrón generaliza a ORFs reales ensamblados de novo a partir de muestras metagenómicas de intestino porcino (proyecto PRJEB11755, ENA). Se entrenaron y compararon una regresión logística y un modelo XGBoost, evaluados bajo una partición que retiene familias completas de genes fuera del entrenamiento para medir generalización genuina en vez de memorización. XGBoost alcanza un ROC-AUC de 0,935 sobre familias de CARD nunca vistas, y un *recall* de 53,0 % al recuperar los ARG ya confirmados por RGI en datos reales, señalando además 2.111 ORFs adicionales como candidatos no catalogados por el método de referencia. Los resultados sugieren una señal composicional real, aunque todavía limitada, principalmente por una cantidad insuficiente de datos, y presencia importante de ruido y diferencias en calidad de información entre los datasets utilizados.

Index Terms—Resistencia a antibióticos, Metagenómica, Aprendizaje automático, k-mers, XGBoost

1 INTRODUCCIÓN

La resistencia de los patógenos a los antibióticos es uno de los mayores problemas de salud pública actuales, con una amenaza creciente hacia el futuro: entre 2019 y 2025 las muertes anuales asociadas a microorganismos resistentes pasaron de 1,9 a 4 millones, con proyecciones de hasta 10 millones de muertes anuales si no se toman medidas de gran impacto [1]. La resistencia surge naturalmente por selección de cepas con mecanismos bioquímicos de defensa, por lo que no puede detenerse por completo; sin embargo, el uso inadecuado o excesivo de antibióticos — preventivo o terapéutico — acelera notablemente su desarrollo, al punto de volver ineficaces tratamientos antes confiables [2, 3].

Las infecciones nosocomiales son el escenario más documentado de este problema, dado el uso extendido de antibióticos de alto espectro en hospitales: aunque las bacterias multirresistentes suelen ser menos virulentas (un "trade-off" evolutivo bien documentado), siguen representando un riesgo considerable para pacientes inmunosuprimidos o vulnerables. El reporte global de Naghavi et al. [1] muestra una mortalidad decreciente en población pediátrica pero creciente en adultos mayores, y un análisis más profundo confirma la estadía hospitalaria como factor de riesgo de morbilidad por microorganismos multirresistentes [4]. Pese a existir una "escalera" de antibióticos para cepas cada vez más resistentes, algunas cepas ya son resistentes a todos los antibióticos conocidos, o suficientemente resistentes para causar sobrecostos importantes o la muerte del paciente antes de aplicar una terapia eficaz.

Un factor subestimado en el desarrollo de resistencia es el uso industrial de antibióticos en la ganadería, tanto de forma preventiva como para promover el crecimiento animal [5]. Se estiman 93.000 toneladas de antibióticos usadas anualmente con fines preventivos en granjas a nivel mundial [2], y el resistoma de estos entornos es más diverso — y específico por especie animal — que el humano o el de suelo [6]. Esto es particularmente preocupante porque cepas ya patógenas en humanos, como la CC398 de *Staphylococcus aureus* Meticilino-Resistente, portan plásmidos de resistencia originados en granjas y transmisibles a humanos [7], representando un riesgo tanto alimenticio como ocupacional para trabajadores del sector.

La Inteligencia Artificial se perfila como una herramienta prometedora frente a este problema [8], tanto en el descubrimiento de nuevos antibióticos — la halcina, primer fármaco descubierto por IA, es activa

contra cepas como SARM o *Acinetobacter baumannii* previamente panresistentes [9], aunque su farmacocinética y toxicidad aún se investigan [10] — como en la detección temprana de cepas multirresistentes antes de que generen impacto en salud pública. Existen múltiples artículos recientes evaluando el uso de ML para predecir la aparición de ARGs en distintas especies [11], notablemente en *Mycobacterium tuberculosis* [12] o en *Salmonella* no tifoidea [13], aunque otras especies más flexibles como *Pseudomonas aeruginosa* todavía no cuentan con un modelo confiable de predicción de resistencia, a pesar de esfuerzos previamente documentados [14].

En este trabajo, presentamos un prototipo experimental de uso de ML para aprender a detectar ARGs previamente identificados en la literatura, y usar esta información para aprender a detectar genes de resistencia distintos a los usados para su entrenamiento. Con esto, buscamos generar un paso previo al problema final de detección de mecanismos emergentes de resistencia a antibióticos.

2 METODOLOGÍA

2.1 Fuente de datos y selección de muestras

Se utilizaron datos metagenómicos crudos del proyecto PRJEB11755 del European Nucleotide Archive (ENA), un estudio de la microbiota intestinal porcina organizado en siete grupos de granja/cohorte (identificados en los metadatos como PIG, EYZ, SYZ, BMZ, BHZ, ZXZ y DB), con 200, 52, 38, 34, 24, 22 y 20 corridas de secuenciación profundas disponibles por grupo, respectivamente. Cada muestra biológica cuenta en ENA con dos corridas asociadas: una profunda (del orden de 2–5 GB comprimidos) y una acompañante de tamaño muy inferior (<100 MB), insuficiente para un ensamblado de novo confiable; se descartaron sistemáticamente estas últimas filtrando por tamaño.

Para este trabajo, se usaron 34 muestras en total, debido a las limitaciones computacionales al momento del desarrollo de este trabajo. Se procuró mantener una proporción representativa de las 7 especies en el muestreo final. Cada corrida de una muestra representa de manera cruda hasta 47 millones de pares de lecturas, lo que es prácticamente intratable a nivel doméstico, por lo que se descargaron a modo de submuestreo aleatorio reproducible de 1000000 pares de lecturas por muestra (seqtk, semilla fija) previo al ensamblado.

2.2 Preprocesamiento y detección de ARG por comparación con catálogo

Para cada corrida se aplicó el siguiente flujo, ejecutado de forma independiente e idempotente por muestra: control de calidad de las lecturas (fastp), submuestreo reproducible (seqtk), ensamblado de novo

• Universidad Nacional de Colombia, Facultad de Ingeniería
• Documento preparado con la plantilla L^AT_EX de IEEE VGTC
(<https://github.com/ieeevgtc/tvcg-journal-latex>).

(MEGAHIT), predicción de genes/ORFs sobre los contigs ensamblados (Prodigal), y detección de genes de resistencia antimicrobiana (ARG) por homología de secuencia contra la base de datos curada CARD, usando la herramienta RGI (BLASTP/DIAMOND) en modo local. Este último paso constituye el método de referencia tipo "diccionario": únicamente detecta secuencias suficientemente similares a un modelo ya catalogado en CARD, y es el resultado que se busca contrastar con el modelo de aprendizaje automático descrito a continuación.

2.3 Conjunto de datos para el modelo de aprendizaje automático

Una vez realizado el preprocesamiento previo al entrenamiento, definimos dos conjuntos de datos para pasar al modelo:

- **Positivos de entrenamiento.** Se extrajeron las secuencias de ADN de referencia de las 6.404 entradas de CARD, agrupadas en 470 familias de genes según su categoría ARO. Como las secuencias de CARD corresponden a genes completos (longitud mediana ≈ 876 pb), mientras que los ORFs reales son fragmentos de un ensamblaje metagenómico submuestreado (longitud mediana ≈ 360 pb en nuestras muestras), cada secuencia de CARD se complementó con tres recortes aleatorios de longitud muestreada de la distribución real observada. Esto evita que el modelo aprenda a distinguir "secuencia completa" en vez de un patrón de resistencia genuino, y produjo 25.616 secuencias positivas de entrenamiento.
- **Negativos de entrenamiento y evaluación del mundo real.** De los 377.345 ORFs reales predichos por Prodigal en las 34 muestras, los 489 que RGI ya identificó como ARG se apartaron como conjunto de evaluación del mundo real y nunca se usaron para entrenar; los 376.856 ORFs restantes constituyen el *pool* negativo de entrenamiento (muestreado 3:1 respecto a los positivos).

2.4 Extracción de características y modelos

Se usó como representación la frecuencia relativa de tetranucleótidos (k-mers de ADN, $k = 4$, 256 dimensiones), una firma composicional libre de alineamiento. Sobre esta representación se entrenaron y compararon dos modelos de clasificación binaria (ARG vs. no-ARG): regresión logística con balanceo de clases, como línea base, y XGBoost como modelo principal. Los dos hiperparámetros de XGBoost con mayor impacto — tasa de aprendizaje (η) y profundidad máxima de los árboles — se eligieron mediante una búsqueda en grilla ($\eta \in \{0.05, 0.1, 0.2\}$, profundidad $\in \{3, 5, 7\}$) evaluada por AUPRC sobre la partición por familia de gen descrita en la siguiente subsección, resultando en $\eta = 0.2$ y profundidad máxima = 7. El número de árboles (M) no se fijó de antemano en ningún caso: se eligió mediante *early stopping* contra una partición de validación separada del conjunto de entrenamiento correspondiente, nunca contra el conjunto de prueba usado para reportar resultados.

2.5 Esquemas de evaluación

Se evaluaron dos particiones sobre los datos derivados de CARD (Sec. 2.3):

- **Partición aleatoria:** reparto 80/20 estratificado por clase.
- **Partición por familia de gen (*holdout*):** se reservaron 94 de las 470 familias completas de CARD exclusivamente para prueba, de forma que ninguna variante de esas familias es vista en entrenamiento.

Finalmente, se entrenó un modelo con la totalidad de los datos derivados de CARD y se aplicó sobre los 377.345 ORFs reales de las 34 muestras, comparando sus predicciones contra las detecciones de RGI mediante dos indicadores: (1) el *recall* sobre los 489 ARG ya conocidos, y (2) el número de ORFs no catalogados por RGI que el modelo marca como ARG probable ("candidatos nuevos"). Un subconjunto de los candidatos de mayor probabilidad se verificó puntualmente mediante BLAST remoto (*megablast*) contra la base nt de NCBI.

Table 1: Desempeño de los modelos de clasificación (positivo = ARG) en las dos particiones de evaluación sobre los datos derivados de CARD.

Partición	Modelo	ROC-AUC	AUPRC	Recall
Aleatoria	Reg. logística	0.921	0.843	0.811
Aleatoria	XGBoost	0.989	0.980	0.900
Por familia (<i>holdout</i>)	Reg. logística	0.831	0.628	0.576
Por familia (<i>holdout</i>)	XGBoost	0.935	0.854	0.514

Table 2: Comparación entre entrenar únicamente con CARD y con una mezcla de CARD + 80 % de ARG reales, con un techo de 3.000 árboles.

Configuración	M	Recall	Candidatos nuevos
CARD (completo)	1.387	0.534 ^a	2.053
CARD + ARG reales (mezcla)	928	0.827 ^b	2.070

^aSobre los 489 ARG reales conocidos (ninguno usado en entrenamiento).

^bSobre los 98 ARG reales apartados exclusivamente para prueba.

3 RESULTADOS

3.1 Muestras procesadas y datos disponibles

Sobre las 34 muestras descargadas, Prodigal predijo 377.345 ORFs, de los cuales RGI confirmó 489 como genes de resistencia por homología contra CARD (0,13 % del total), proporción consistente con lo esperado en una muestra metagenómica no enriquecida para ARG.

3.2 Desempeño del modelo sobre los datos de CARD

La Tab. 1 resume el desempeño de ambos modelos en las dos particiones de evaluación.

En la partición aleatoria, ambos modelos alcanzan un desempeño alto (XGBoost: ROC-AUC=0,989, AUPRC=0,980). La partición por familia (que retiene 94 de las 470 familias en el entrenamiento) muestra que XGBoost mantiene un desempeño por encima del azar en ROC-AUC y AUPRC (0,935 y 0,854, respectivamente), aunque su *recall* sobre la clase positiva a un umbral de 0,5 cae a 0,514; la regresión logística obtiene un desempeño menor en todas las métricas (ROC-AUC=0,831, AUPRC=0,628, *recall*=0,576).

3.3 Desempeño sobre datos reales y candidatos nuevos

Al aplicar el modelo final (entrenado con la totalidad del conjunto derivado de CARD) sobre los 377.345 ORFs reales, el *recall* sobre los 489 ARG ya confirmados por RGI fue de 53,0 %, un valor comparable al observado en la partición por familia sobre datos de CARD (51,4 %; Tab. 1).

El modelo marcó adicionalmente 2.111 ORFs (0,56 % del *pool* negativo) como ARG probable sin que RGI los hubiera catalogado. Como verificación puntual, se sometieron a BLAST remoto (*megablast* contra nt) los cinco candidatos de mayor probabilidad ($\geq 0,98$); ninguno correspondió a un gen de resistencia conocido: tres tuvieron como mejor coincidencia genomas bacterianos completos o ensamblajes metagenómicos sin anotación funcional de resistencia asociada (*Salmonella enterica* subsp. *enterica* serovar Kentucky, un MAG de *Clostridiales*, y un MAG de *Alistipes* sp.), y los dos restantes no obtuvieron ningún hit en BLAST. Esto es consistente con falsos positivos originados en similitud composicional genérica (p. ej., contenido GC o sesgo de codones típico de ciertos genomas bacterianos) más que en homología funcional real con un gen de resistencia, aunque la ausencia de hit en dos de los cinco candidatos no permite descartar que correspondan a secuencias genuinamente no catalogadas.

3.4 Efecto de incluir ARG reales en el entrenamiento

Se comparó el modelo entrenado únicamente con CARD frente a una variante entrenada con una mezcla de CARD y el 80 % de los ARG reales confirmados (391 de 489 secuencias), repitiendo en ambos casos la elección de M con un techo de 3.000 árboles para descartar que el valor elegido por *early stopping* quedara truncado artificialmente. Table 2 resume los resultados.

En ambos casos M convergió genuinamente sin acercarse al techo de 3.000, confirmando que el techo original de 1.000 árboles no truncaba artificialmente el entrenamiento. La mezcla de CARD con ARG reales muestra un *recall* considerablemente mayor (82,7 %) que el modelo entrenado únicamente con CARD (53,4 %), sin afectar negativamente el *recall* sobre familias de CARD retenidas para prueba (51,7 % frente a 51,4 %).

De los 489 ARG reales confirmados, solo 39 corresponden a genes distintos (según `Best_Hit_ARO` de CARD/RGI), es decir, cada gen aparece en promedio en $\sim 12,5$ muestras distintas. Al particionar estas secuencias al azar (sin controlar por identidad de gen, a diferencia de la partición por familia usada para CARD), el 99,0 % de las 98 secuencias de prueba corresponden a un gen que ya apareció en las 391 secuencias de entrenamiento. Esto implica que el *recall* de 82,7 % mide en buena medida el reconocimiento de instancias adicionales de un gen ya visto, más que la generalización a un gen genuinamente nuevo.

Se puede consultar el código fuente del proyecto en el siguiente [link](#).

4 CONCLUSIONES

4.1 Interpretación de los resultados

La brecha entre regresión logística y XGBoost en la partición por familia (ROC-AUC 0,831 vs. 0,935; [Tab. 1](#)) confirma que la composición de tetranucleótidos contiene una señal genuinamente no lineal asociada a "gen de resistencia": un modelo lineal en frecuencias de k-mers no alcanza a capturarla, mientras que un ensamble de árboles, capaz de modelar interacciones entre k-mers y no solo sus efectos aditivos, sí extrae algo más allá de la memorización de secuencias de entrenamiento. Sin embargo, un *recall* de apenas 0,514 sobre familias nunca vistas, incluso con el modelo ganador, muestra que esa señal aún no basta para clasificar correctamente la mayoría de las familias genuinamente nuevas. Sobre datos reales, el *recall* de 53,0 % resultó comparable al de la partición por familia (51,4 %) — una brecha mucho menor que en una etapa temprana de este trabajo con un conjunto de muestras más pequeño, donde el desempeño sobre datos reales caía muy por debajo del desempeño sobre CARD. Esto sugiere que aquella brecha inicial era, al menos en parte, un artefacto de un conjunto de evaluación pequeño y no necesariamente una barrera de dominio irreductible; aun así, un *recall* de poco más de la mitad sigue lejos de un desempeño confiable para uso práctico.

La búsqueda de hiperparámetros arrojó una mejora real pero modesta en el AUPRC de validación ($\sim 0,839$ a $0,860$) al mover η y la profundidad máxima. Sin embargo, el hallazgo más importante de esa búsqueda no es la mejora en sí, sino que *todas* las combinaciones de la grilla alcanzaron un AUPRC de entrenamiento cercano a 1,0, incluso las configuraciones más conservadoras: la capacidad del modelo no es el cuello de botella, y la brecha *training-testing* persistentemente alta ($\sim 0,14$ – $0,16$) es más informativa sobre la naturaleza del problema (redundancia dentro de las familias de CARD, brecha de dominio CARD-vs-real) que sobre una elección subóptima de hiperparámetros. Finalmente, la comparación CARD-vs-mezcla ([Tab. 2](#)) ilustra un riesgo metodológico central en este tipo de tareas: el *recall* aparentemente superior de la mezcla (82,7 %) resultó estar inflado por una redundancia de identidad de gen entre entrenamiento y prueba (99,0 % de solapamiento) que una partición puramente aleatoria no logró prevenir. El valor de 53,4 % obtenido entrenando únicamente con CARD sigue siendo, por tanto, la estimación más confiable de generalización genuina disponible en este trabajo.

4.2 Justificación de las decisiones de diseño

Representación por k-mers en vez de alineamiento. Se eligió la frecuencia de tetranucleótidos — la "firma genómica" usada en *binning* taxonómico reference-free — precisamente porque RGI/BLAST ya resuelven la tarea de alineamiento contra CARD de forma confiable; repetir ese mecanismo con otro algoritmo no habría aportado nada nuevo. La composición de k-mers pregunta algo distinto y complementario: si la textura estadística local de una secuencia se parece a la de un gen de resistencia conocido, sin necesidad de una coincidencia catalogada.

XGBoost como modelo principal. Se consideraron alternativas de mayor capacidad — una CNN 1D sobre la secuencia *one-hot*, o modelos tipo *transformer* preentrenados sobre secuencias genómicas o proteicas — capaces de capturar motivos locales y su posición, información que un vector de frecuencias de k-mers descarta por construcción. Se optó, sin embargo, por establecer primero, con un modelo clásico y liviano ejecutable en un portátil, si existe siquiera una señal composicional aprovechable, antes de invertir en arquitecturas de mayor costo computacional; la comparación directa contra regresión logística permite además aislar el efecto de capturar interacciones no lineales entre k-mers.

Partición por familia de gen en vez de partición aleatoria. Esta es, en retrospectiva, la decisión metodológica más importante de todo el trabajo. Cualquier tarea de ML en bioinformática donde las secuencias positivas provienen de una base de datos curada corre el riesgo de que variantes casi idénticas de una misma familia queden repartidas entre entrenamiento y prueba, inflando artificialmente el desempeño reportado — exactamente lo que se observa al comparar la partición aleatoria (ROC-AUC 0,989) contra la partición por familia (0,935). La necesidad de este control no es solo teórica: se confirmó empíricamente en sentido inverso al analizar la comparación CARD-vs-mezcla, donde la ausencia de un control equivalente por identidad de gen produjo el mismo tipo de fuga de información.

Fragmentación de las secuencias de CARD. Las secuencias de referencia de CARD son genes completos; los ORFs reales son fragmentos de un ensamblaje submuestreado. Fragmentar CARD según la distribución de longitud observada en los ORFs reales elimina el atajo trivial de aprender a distinguir "secuencia completa" de "fragmento" en vez de un patrón de resistencia genuino.

Selección de hiperparámetros por validación empírica. El espacio de hipótesis efectivo de un ensamble de cientos de árboles es astronómicamente más grande que el tamaño de la muestra de entrenamiento ($N \approx 10^5$); las cotas de generalización clásicas basadas en conteo de hipótesis (Hoeffding, dimensión VC) son, en este régimen, esencialmente vacías. La única señal confiable sobre generalización disponible es, entonces, puramente empírica: medir el desempeño en una partición de validación genuinamente separada y dejar que esa medición determine tanto los hiperparámetros como el número de árboles M vía *early stopping*.

Log-loss como función de pérdida. Es la elección de máxima verosimilitud para una etiqueta Bernoulli bajo un enlace logístico, y una regla de puntuación propia que premia estimaciones de probabilidad bien calibradas, no solo decisiones binarias correctas. Esto importa porque `proba_arg` se usa para *ordenar* candidatos por probabilidad, no solo para clasificarlos.

4.3 Sesgos y limitaciones

- Desajuste del *prior* de clase.** El modelo se entrena con una tasa positiva artificial de ~ 25 % (por el submuestreo 3:1) pero se aplica, a un umbral fijo de 0,5, sobre datos reales donde la tasa positiva real es $\sim 0,13$ % — casi 200 veces más rara que en entrenamiento. Sin una corrección de calibración (p. ej. *Platt scaling*), es esperable que el modelo sobre-prediga positivos en datos reales; una fracción no despreciable de los 2.111 "candidatos nuevos" probablemente sea, en parte, un artefacto de esta falta de calibración y no señal genuina.
- Techo estructural impuesto por el catálogo de CARD.** El 100 % de la señal positiva de entrenamiento proviene de mecanismos de resistencia ya publicados y caracterizados en CARD. El modelo puede, en el mejor de los casos, generalizar a variantes no vistas de familias ya conocidas; no tiene ninguna posibilidad de aprender un mecanismo de resistencia genuinamente inédito.
- Ruido de etiqueta en el *pool* negativo.** Los ORFs "negativos" son, estrictamente, ORFs que RGI no marcó — no negativos verificados. Es esperable que una fracción de ese *pool* corresponda a ARG genuinos aún no descritos, lo cual introduce ruido de etiqueta y hace imposible separar limpiamente un "candidato nuevo" real de un falso positivo ordinario.

- **Redundancia dentro de las familias de CARD.** Muchas de las 6.404 secuencias de CARD son variantes alélicas casi idénticas dentro de una misma familia; aunque la partición por familia evita la fuga de información entre entrenamiento y prueba, no elimina la falta de independencia dentro de cada partición, por lo que el tamaño de muestra efectivo es menor que el nominal.
- **Varianza de una sola partición.** Todas las particiones de evaluación usan una única semilla fija, sin validación cruzada; no hay manera de saber cuánto de cada número reportado depende de qué familias cayeron, por azar, en el conjunto de prueba.
- **Sesgo de población de muestra.** Los 489 ARG reales provienen de 34 muestras metagenómicas de intestino porcino de un único proyecto de ENA; cualquier afirmación sobre desempeño "en el mundo real" es específica a este contexto y no se extiende automáticamente a otros ambientes.
- **Sesgo de confirmación en la verificación por BLAST.** Solo se verificaron puntualmente los 5 candidatos de mayor probabilidad de un total de 2.111; esto no permite estimar la precisión real sobre el resto de la lista sin un muestreo más amplio.
- **Fuga de identidad de gen en la comparación CARD-vs-mezcla.** El 99,0 % de las secuencias de prueba de ese experimento comparten identidad de gen con el conjunto de entrenamiento, lo cual infla el *recall* reportado para esa configuración.

4.4 Conclusiones finales

En un contexto mundial, en el que el desarrollo de mecanismos de resistencia por parte de microorganismos patógenos, claramente sobrepasa a la capacidad de la humanidad para hacer contrapeso, desarrollar habilidades predictivas sobre mecanismos de resistencia es crucial. Sin embargo, los datasets, y modelos asociados para informar sobre vías de señalización y mutaciones emergentes todavía son bastante limitados.

Este trabajo permite explorar un mecanismo potencial para aprender a detectar genes que puedan evolucionar eventualmente a mecanismos de resistencia, al modificar deliberadamente los conjuntos de entrenamiento y testing, para verificar su capacidad de marcar etiquetas positivas con ejemplos nunca antes vistos. Sin embargo, desde el inicio del planteamiento se advierte que cualquier tipo de verificación riguroso requiere una mayor cantidad de datos, así como una mayor capacidad computacional. Esto incluye evaluar hiperparámetros que sobrepasaron las capacidades del computador usado para estos resultados (como por ejemplo, el uso de un k mayor a 4, o un M mayor a 3000).

Incluso una validación aceptable del potencial de este mecanismo se queda corto para todos los desafíos correspondientes a este problema. Se sobreentiende que el uso de muestras enteras lograría mejores resultados que la estrategia de submuestreo utilizada por motivos pragmáticos. Igualmente, la estrategia actual de k -mers es limitada para información de contexto por posición del k -mer. Se necesita abordar con mayor profundidad la diferencia en ruido entre las distintas secuencias utilizadas (CARD vs. RGI), y finalmente, cualquier resultado obtenido debe poder ser molecularmente viable y demostrable in vitro, para lo cual los modelos pre-entrenados son de particular utilidad.

REFERENCES

- [1] GBD 2021 Antimicrobial Resistance Collaborators, "Global burden of bacterial antimicrobial resistance 1990–2021: a systematic analysis with forecasts to 2050," *Lancet*, vol. 404, pp. 1199–1226, Sept. 2024. 1
- [2] World Health Organization, "Global antibiotic resistance surveillance report 2025," tech. rep., World Health Organization, Geneva, Oct. 2025. 1
- [3] UK Health Security Agency, "English surveillance programme for antimicrobial utilisation and resistance (ESPAUR) report 2024 to 2025," tech. rep., UK Health Security Agency, London, Nov. 2025. 1
- [4] N. A. George, D. Pan, L. Silva, R. F. Baggeley, P. Irizar, P. Divall, A. Al-Oraibi, D. P. Khan, C. A. Martin, J. Nazareth, I. Collins, S. L. Chew, L. B. Nellums, and M. Pareek, "The prevalence and risk of mortality associated with antimicrobial resistance within nosocomial settings—a global systematic review and meta-analysis of over 20,000 patients," *eClinicalMedicine*, vol. 87, Sept. 2025. 1
- [5] M. E. Doyle, "Multidrug-resistant pathogens in the food supply," *Food-borne Pathog Dis*, vol. 12, pp. 261–279, Apr. 2015. 1
- [6] B. Li, L. Jiang, T. Johnson, G. Wang, W. Sun, G. Wei, S. Jiao, J. Gu, J. Tiedje, and X. Qian, "Global health risks lurking in livestock resistome," *Sci Adv*, vol. 11, June 2025. 1
- [7] M. Matuszewska, G. G. R. Murray, X. Ba, R. Wood, M. A. Holmes, and L. A. Weinert, "Stable antibiotic resistance and rapid human adaptation in livestock-associated MRSA," *eLife*, vol. 11, June 2022. 1
- [8] A. Howard, N. Reza, P. L. Green, M. Yin, E. Duffy, H. C. Mwandumba, A. Gerada, and W. Hope, "Artificial intelligence and infectious diseases: tackling antimicrobial resistance, from personalised care to antibiotic discovery," *Lancet Infect Dis*, vol. 26, pp. e181–e192, Mar. 2026. 1
- [9] I. El Belghiti, O. Hammani, F. Moustaooui, M. Aghrouh, Z. Lemkhente, F. Boubrik, and A. Belmouden, "Halicin: A new approach to antibacterial therapy, a promising avenue for the post-antibiotic era," *Antibiotics (Basel)*, vol. 14, p. 698, July 2025. 1
- [10] M. Zhang, S. Lin, L. Han, J. Zhang, S. Liu, X. Yang, R. Wang, X. Yang, and Y. Yi, "Safety and efficacy evaluation of halicin as an effective drug for inhibiting intestinal infections," *Front Pharmacol*, vol. 15, May 2024. 1
- [11] J. I. Kim, F. Maguire, K. K. Tsang, T. Gouliouris, S. J. Peacock, T. A. McAllister, A. G. McArthur, and R. G. Beiko, "Machine learning for antimicrobial resistance prediction: Current practice, limitations, and clinical perspective," *Clin Microbiol Rev*, vol. 35, no. 3, 2022. 1
- [12] Y. Yang, T. M. Walker, A. S. Walker, D. J. Wilson, T. E. A. Peto, D. W. Crook, F. Shamout, T. Zhu, and D. A. Clifton, "DeepAMR for predicting co-occurrent resistance of mycobacterium tuberculosis," *Bioinformatics*, vol. 35, no. 18, pp. 3240–3249, 2019. 1
- [13] M. Nguyen, S. W. Long, P. F. McDermott, R. J. Olsen, R. Olson, R. L. Stevens, G. H. Tyson, S. Zhao, and J. J. Davis, "Using machine learning to predict antimicrobial MICs and associated genomic features for nontyphoidal salmonella," *J Clin Microbiol*, vol. 57, no. 2, 2019. 1
- [14] A. Jain, G. R. Dabburu, B. Samanta, N. Singhal, and M. Kumar, "An explainable machine learning pipeline for prediction of antimicrobial resistance in pseudomonas aeruginosa," *Bioinform Adv*, vol. 5, no. 1, 2025. 1